Chống tấn công đầu độc mô hình trong Học liên kết phi tập trung (DFL) dựa trên lý thuyết trò chơi

Tổng hợp các thí nghiệm đã chạy và kết quả

Setup · Utility · Mô hình trò chơi · B1 → B7 · Kiểm tra all-D Nash

11/2026 · nguồn: `ROADMAP.md`, `GAME_FORMULATION.md`, `experiments/`, `experiments/results/`

Câu hỏi nghiên cứu và hai giai đoạn thực nghiệm

Câu hỏi: trong DFL giữa các node cạnh tranh, có thiết kế được **luật nhận/gửi cục bộ W** sao cho đầu độc tham số **mất lợi thế** (không chỉ giảm thiệt hại), và vẫn giữ chất lượng mô hình toàn mạng?

Giai đoạn 1 — game hai node, utility thị trường

`ROADMAP.md` §3, `GAME_FORMULATION.md`, code ở `../dacn/experiments/`

- Ring 4 node / cặp 2 node, hành động rời rạc D/A
- Payoff = thị phần khách hàng (softmax) − chi phí
- Stage Nash, replicator, best response 1–3 bước, policy game
- Thử W0 gate, W1 mixture, reputation, ledger, learner

Giai đoạn 2 — chuỗi B1→B7 + all-D, utility theo λ

`experiments/dfl_lambda.py`, `b4_nash.py`, `alld_check.py`

- Lattice 4×4 (16 node), MNIST non-IID
- Cường độ tấn công liên tục λ, utility tuyến tính trong q
- Best response 1 attacker → Nash N người → all-D Nash
- So sánh 7 defense, thiết kế W2 (gate + trừng phạt có ân xá)

Kết luận ngắn: giai đoạn 1 cho thấy **giảm thiệt hại ≠ răn đe**; giai đoạn 2 đo răn đe trực tiếp bằng **chi phí tấn công tới hạn** c^* và tìm được W2 làm c_A^* giảm ≈ 9–16× so với uniform.

Phần I — Game hai node, utility thị trường

Giai đoạn 1 (ROADMAP §2–§3): bằng chứng âm dẫn tới thiết kế lại

Giai đoạn 1: setup và mô hình trò chơi

Setup

- MNIST, MLP 784⟶64⟶10, SGD lr 0.1, batch 64, 1 epoch/vòng
- 1024 train + 200 val/node; non-IID Dirichlet $\alpha = 1$
- Tấn công sign-flip khuếch đại (scale 5): $m_i^t = w_i^t - 5(\ell_i^t - w_i^t)$, model cục bộ vẫn sạch
- Mỗi vòng mỗi node chọn **D** (gửi sạch) hoặc **A** (đầu độc)

Utility (thị trường)

$$s_{ig}^t = \frac{\exp\left[\kappa\left(q_{ig}^t - \tau_t\right)\right]}{1 + \sum_j \exp\left[\kappa\left(q_{jg}^t - \tau_t\right)\right]}$$

$$\bar{u}_i^{t+1} = \sigma_i^{t+1} - \bar{c}_i^t, \quad \sigma_i = \sum_g \mu_g s_{ig}$$

$\kappa = 10$, $\tau_t = \min(0.8, 0.1 + 0.05t)$, $c_D = 0.005$, $c_A = 0.006$, $\gamma = 0.95$, $T = 20$

Mô hình trò chơi

- Stage game 2 người (DD, AD, DA, AA), Nash thuần/hỗn hợp
- Replicator: $\dot{x} = x(1-x)[f_A(x;W) - f_D(x;W)]$; A xâm nhập nếu $f_A(0^+) > f_D(0^+)$
- Best response chính xác: cây trạng thái, 128 policy tất định, chân trời 1–3 bước
- Policy game: 4 bundle đóng băng × 16 profile

Luật trọng số thử nghiệm

- W0 gate: nhận m_j nếu $L_i(m_j) \le L_i(\ell_i) + 1.0$
- W1: trộn $\lambda \in \{0, .125, .25, .5\}$ theo val-loss
- Reputation + access, earned-access ledger, local learner

Giai đoạn 1: kết quả chính (đều âm về răn đe)

§	Thí nghiệm	Số liệu	Kết luận
3.2	Pilot 42 run, ring 4 node	non-IID: sạch 87.95%, A thích ứng + W0 80.43%; A-rate ≈ 0.50	giảm thiệt hại, không răn đe
3.6	Stage Nash, 18 snapshot × 3 cơ chế	uniform: 18/18 AA; W0: 12 AA, 3 AD/DA, 3 DD (DD = loại hết hàng xóm)	**âm**
3.8	W1 mixture, 72 cây H1–3	A vẫn có trọng số dương 156/1512; xâm nhập đơn phương có lợi 16/36	**âm**
3.9	Chất lượng sạch W1	non-IID mất 4.22 pp so với W0, chỉ hơn local-only 0.82 pp	**âm**
3.10	Reputation–reciprocity	always-A vẫn lãi +0.333; loại nhầm node trung thực	**âm**
3.14	Probe K = 1/2/4/8	always-A vẫn dương; endgame: A ở vòng cuối có lợi 9/9 root non-IID	chưa kết luận
3.18	Policy game 4 bundle, 4704 episode	(attack-if-send)^2 là Nash thuần duy nhất; chất lượng 74.68% vs D/D 85.96%	**âm**
3.19	Utility ký quỹ có audit	định lý điều kiện; chưa triển khai	đề xuất

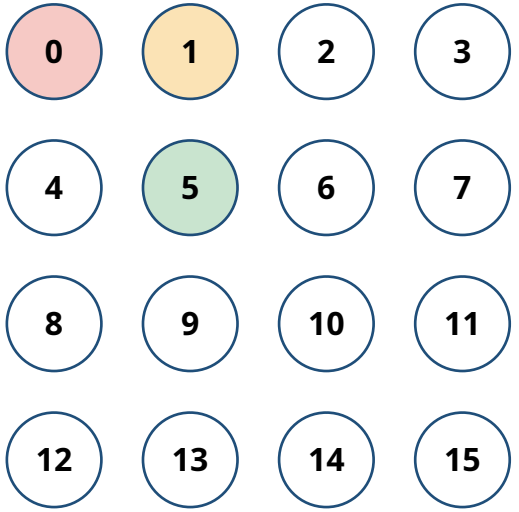
Bài học: (1) lọc tốt không làm tấn công bất lợi; (2) utility thị trường + hành động nhị phân khó tách tác động; (3) cần đo **incentive** trực tiếp, trên mạng nhiều node, với cường độ tấn công liên tục → Phần II.

Phần II — Chuỗi thí nghiệm B1 → B7 → all-D

Utility tuyến tính theo chất lượng, cường độ tấn công λ, mạng 16 node

Setup chung (mọi thí nghiệm B1–B7, all-D)

Dữ liệu	MNIST 60k official-train; **official test không bao giờ được nạp**
Chia tách	80% train pool / 100 ảnh/lớp audit cân bằng (1000) / phần còn lại làm val; kiểm tra không rò rỉ
Non-IID	Dirichlet $\alpha = 1.0$ trên nhãn; 1024 train + 200 val mỗi node
Val	`local` (theo phân phối node) hoặc `balanced` (20 ảnh/lớp, B7)
Mô hình	MLP 784 → 64 ReLU → 10, SGD lr 0.1, batch 64, 1 epoch/vòng
Topology	Lattice 4×4, láng giềng von Neumann (bậc 2/3/4)
Thời gian	$T = 40$ vòng đồng bộ, tấn công từ vòng $s = 10$
Seeds	search {7,19,31,43,59}; holdout {61,67,71,73,79}
Đo chất lượng	q_i: acc trên val của node; **audit**: acc trên tập cân bằng



Vị trí attacker trong B2/B3/B5–B7:
0 góc (bậc 2) · **1** cạnh (bậc 3) · **5** trong (bậc 4)

RNG huấn luyện khóa theo (seed, node, vòng) → các run chỉ khác λ là **cặp** (paired): mọi thiệt hại = clean − attacked cùng seed.

Mô hình tấn công: cường độ liên tục λ

Mỗi vòng t, node i (đang phục vụ model w_i^t):

$$\ell_i = \mathrm{SGD}(w_i^t) \qquad m_i = \ell_i - \lambda_i^t(\ell_i - w_i^t) \qquad w_i^{t+1} = \mathrm{AGG}_i\big(\ell_i, \{m_j : j \in \mathcal{N}_i\}\big)$$

- $\lambda = 0$: trung thực (gửi ℓ_i)
- $\lambda = 1$: gửi lại w_i^t (free-ride, không đóng góp)
- $\lambda > 1$: đảo chiều + khuếch đại cập nhật (đầu độc)
- Attacker **giữ model cục bộ sạch** ℓ_i; chỉ message bị thao túng

- Lưới λ: {0.5, 1, 2, 3, 4, 5, 6, 8, 10, 12, 16} (B1–B6) {2, 3, 4, 5, 6, 8, 12(, 16)} (B7, all-D)
- Tấn công tĩnh: λ cố định từ vòng 10 đến 40 (lớp chính sách giới hạn)
- Attacker vẫn chạy cùng luật nhận W như mọi node

Hệ quả quan trọng: tấn công làm hại láng giềng **và quay lại hại chính attacker** qua bước tổng hợp vòng sau (“own drop”) — đây là kênh răn đe tự nhiên.

Utility và chuẩn hóa

$$u_i = \alpha_1 q_i + \alpha_2 \bar{q}_i + \alpha_3 (q_i - \bar{q}_i) - \gamma\kappa\lambda_i^2$$

q_i: chất lượng của i; $\bar{q}_i$: trung bình láng giềng; α_3: lợi ích **vị thế tương đối** (cạnh tranh); $\gamma\kappa\lambda^2$: chi phí tấn công.

Viết lại $u_i = (\alpha_1 + \alpha_3) q_i - (\alpha_3 - \alpha_2)\bar{q}_i - \gamma\kappa\lambda_i^2$, chia cho $\alpha_3 - \alpha_2 > 0$:

$$U_i = \sum_t w_t \left[\rho\, q_i^t - \bar{q}_i^t\right] - c\,\lambda_i^2, \quad \rho = \frac{\alpha_1 + \alpha_3}{\alpha_3 - \alpha_2} > 1, \quad c = \frac{\gamma\kappa}{\alpha_3 - \alpha_2}, \quad w_t \propto 0.95^t$$

Lợi ích của tấn công so với trung thực (paired):

- một lần: $G_1(\lambda) = D_1(\lambda) - c\lambda^2$
- lặp: $G_R(\lambda; \rho) = \sum_k w_k [D_k - \rho \mathrm{Own}_k] - c\lambda^2$

D_k = sụt $\bar{q}$ láng giềng, Own_k = sụt q của attacker sau k vòng.

Chi phí tới hạn

$$c^* = \max_\lambda \frac{V(\lambda)}{\lambda^2}$$

tấn công có lợi $\Leftrightarrow c < c^*$. Biến thể **chi phí hằng** (B7, all-D):
$U_i = \ldots - c_A \mathbb{1}[s_i > 0]$, all-D là Nash $\Leftrightarrow c_A \geq c_A^* = \max_i \max_s G_i(s)$. Nếu $\alpha_3 \leq \alpha_2$ thì không λ > 0 nào có lợi.

Mô hình trò chơi và giao thức thống kê

B3 — Best response 1 attacker
Mọi node khác trung thực. Tính $V(\lambda)$ từ các run cặp B2 (không train thêm), suy ra $\lambda^*(c, \rho)$ và c^* cho game một lần và lặp.

B4 — Nash N người
Cả 16 node chiến lược, mỗi node chọn $\lambda_i \in \{0, 4, 5, 6, 8, 10, 12\}$. Iterated best response (Gauss–Seidel, node 0⟶15); hội tụ khi một sweep không có node đổi.

all-D check
Mỗi node lệch đơn phương $s \in \{2, ..., 16\}$, 16 × 8 profile. Chọn s_i trên search seeds, ước lượng $G_i(s_i)$ trên **holdout** ⟶ không bias chọn lựa.

Quy tắc ý nghĩa thống kê (5 seed cặp):

- Một λ chỉ được tính là có lợi nếu $\overline{G} > t_{0.975,4} \cdot \mathrm{SE} = 2.776 \cdot \mathrm{SE}$; ngược lại bị loại ⟶ nhiễu seed không tạo ra "tấn công có lợi" giả.
- B4: node chỉ đổi chiến lược nếu cải thiện có ý nghĩa; Nash = **Nash thống kê trên lưới λ**.
- `verify_nash.py`: kiểm tra lại từng attacker của profile Nash trên 5 holdout seed.
- Mọi kết quả báo cáo cho cả hai thước đo chất lượng: q (val cục bộ, chính) và **audit** cân bằng (độ nhạy).

Thang thí nghiệm

B1 baseline
DFL sạch vs local-only: hợp tác có lợi không?

→

B2 + attack
1 attacker, $\lambda \in [0.5, 16]$: đường thiệt hại $D(\lambda)$, lan truyền theo hop

→

B3 incentive
Best response $\lambda^*(c, \rho)$, chi phí tới hạn c^*

→

B4 Nash N người
Iterated BR trên 16 node, kiểm tra holdout

↓

B5 + defense
gate, median, trimmed, clip, BALANCE

←

B6 + recip
Gate + cắt gửi theo trust; Nash theo metric audit

←

B7 W2
Val cân bằng, tol hiệu chuẩn 0.3, trừng phạt L vòng + ân xá G

←

all-D check
Lệch đơn phương, search/ holdout, c_A^* theo W

Script: `dfl_lambda.py` (B1, B2, B5, B6, B7) · `analyze_b1_b2.py` · `analyze_b3.py` · `b4_nash.py` (B4, B5/B6 Nash) · `verify_nash.py` · `analyze_b5.py` · `analyze_b6.py`, `calib_b6.py` · `analyze_b7.py` · `alld_check.py`

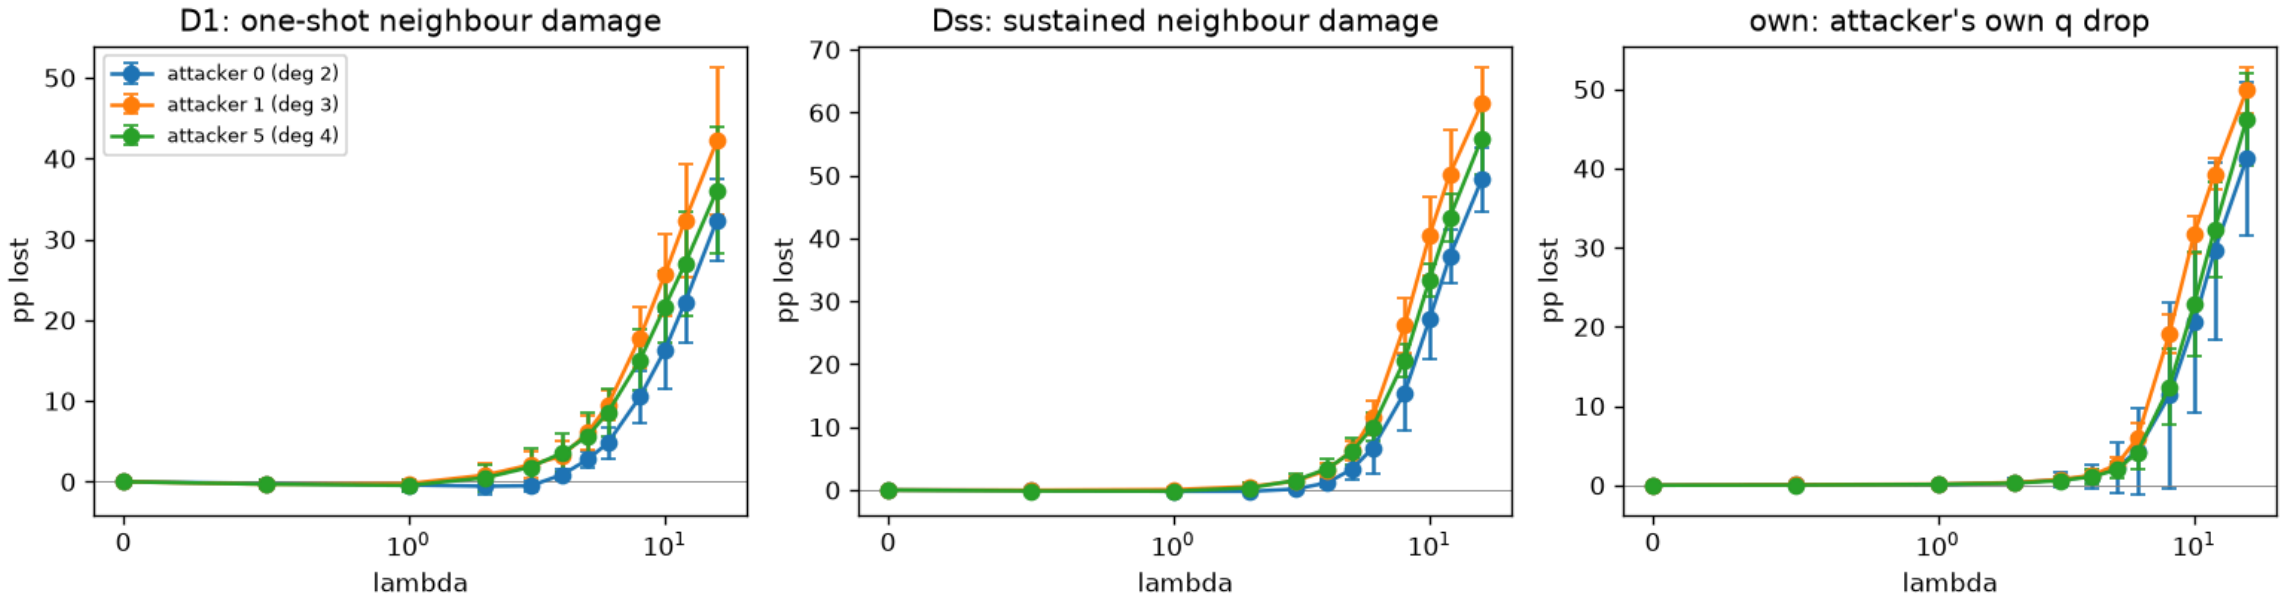
B1 — Baseline: DFL sạch so với local-only

	q (val cục bộ)	q min-node	audit cân bằng	audit min-node
local-only	90.24 ± 0.66	85.38 ± 1.51	77.05 ± 2.06	65.69 ± 1.42
DFL uniform	91.88 ± 0.38	87.99 ± 1.27	**89.87 ± 0.66**	**88.70 ± 0.71**

% , trung bình 10 vòng cuối, mean ± sd trên 5 seed

- DFL tăng audit ở **80/80** node-seed (trung bình **+12.82 pp**), q tăng ở 66/80 (+1.64 pp).
- Node yếu nhất được lợi nhiều nhất: audit min-node 65.7 → 88.7.
- ⇒ Có **động cơ tham gia** hợp tác; tấn công có giá trị để phá hoại → đáng mô hình hóa.
- q cục bộ "dễ" hơn (đo trên phân phối lệch của node) nên khoảng cách nhỏ; audit phản ánh chất lượng toàn cục.

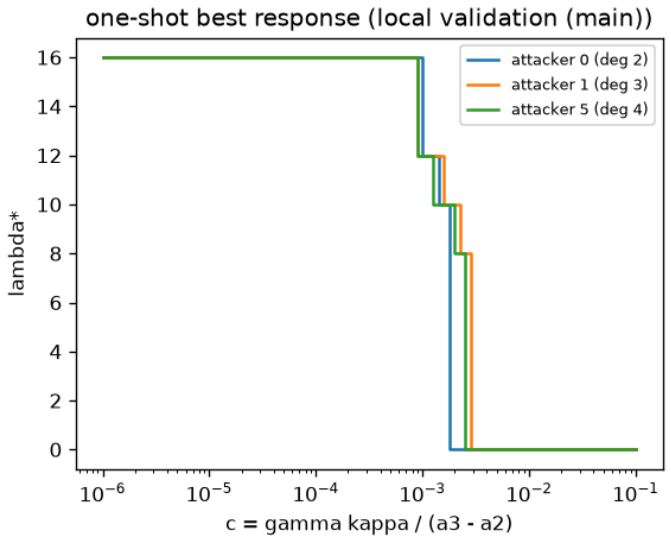
B2 — Thêm attack: đường thiệt hại D(λ) (aggregation uniform)

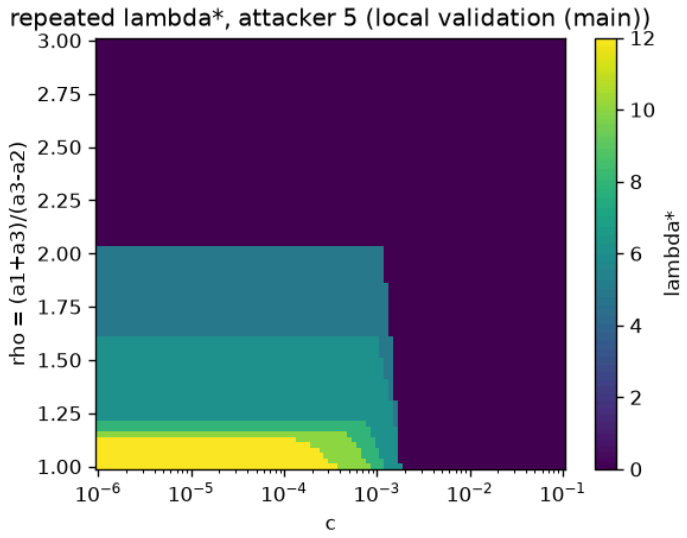


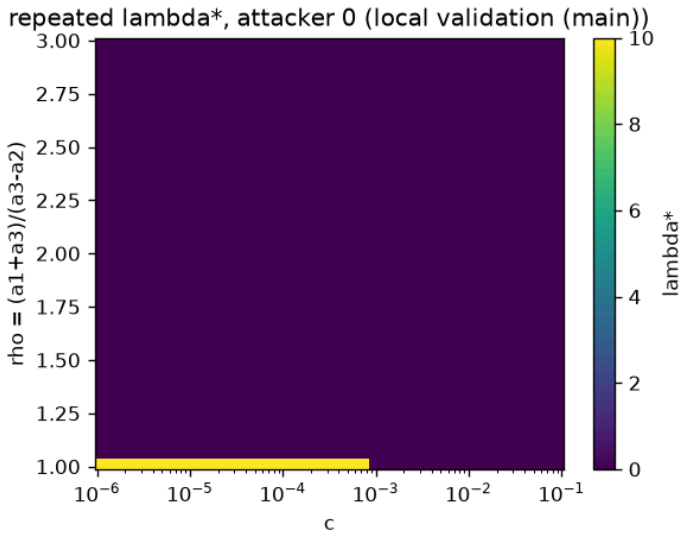
λ (att. 5)	**D1**	**Dss**	**own**	**net audit**	**hop1/2/3+**
1	−0.45	−0.18	0.11	0.08	−0.2/0.1/0.1
4	3.60	3.40	1.09	1.42	3.4/0.6/0.4
8	15.05	20.64	12.44	12.97	20.6/5.1/1.7
16	36.08	55.92	46.16	45.48	55.9/26.7/13.0

- λ ≤ 2: không gây hại (nhiễu ±1 pp); ngưỡng ≈ λ 3–4, sau đó **lồi**.
- Thiệt hại lan theo hop, giảm ≈ ½ mỗi hop.
- "own" lớn: attacker tự chịu ≈ 60–85% thiệt hại của láng giềng (λ ≥ 8) ⟹ ρ có vai trò răn đe.
- Node cạnh (bậc 3) gây hại nhiều nhất.

B3 — Best response của một attacker (uniform)







c* (metric q)	một lần	ρ=1	ρ=1.25	ρ=2	ρ=3
att 0 (bậc 2)	1.64e-3	8.3e-4	–	–	–
att 1 (bậc 3)	2.79e-3	1.66e-3	1.35e-3	–	–
att 5 (bậc 4)	2.38e-3	1.80e-3	1.63e-3	1.18e-3	–
att 5, audit	2.23e-3	2.25e-3	2.03e-3	1.51e-3	–

- **Nhảy bậc**: khi c vượt xuống dưới c^*, λ^* nhảy 0 ⟶ 6 (att 5) — không có vùng "tấn công nhẹ".
- Game lặp + ρ lớn ⟹ tự hại răn đe: ρ = 3 không còn λ có lợi.
- Theo audit, tấn công có lợi ở ρ cao hơn (own drop đo trên audit nhỏ hơn).

B4 — Nash N người (16 node chiến lược, uniform, metric q)

ρ	c	Profile Nash (λ ≠ 0)	q: all-D → Nash	audit: all-D → Nash	holdout
1.25	1e-4	node 1, 11: λ = 6	91.88 → 83.30	89.87 → 79.67	0/2 còn ý nghĩa
1.25	1e-3	all-D	91.88	89.87	—
1.5	1e-4	node 5: λ = 6	91.88 → 87.03	89.87 → 84.79	0/1
1.5	1e-3	all-D	91.88	89.87	—
2.0	1e-4, 1e-3	all-D	91.88	89.87	—

- BR hội tụ trong ≤ 2 sweep; 815–1675 mô phỏng mỗi cấu hình.
- Chỉ 1–2 attacker xuất hiện, nhưng đã làm q trung bình **cả mạng** mất 4.9–8.6 pp.
- Kiểm tra trên holdout: lợi ích của các attacker **không còn ý nghĩa** (vd. node 1: −0.047, SE 0.012) ⟹ đây là cân bằng biên/nhiễu, nhưng cho thấy uniform **không chặn** được tấn công khi c nhỏ.
- Với $c \geq 10^{-3}$ hoặc $\rho \geq 2$: all-D là Nash thống kê → khớp với c^* ở B3.

B5 — Thêm defense: chi phí khi sạch và thiệt hại

Defense	q	audit	audit min
uniform	91.88	89.87	88.70
gate (tol 1.0)	91.90	89.88	88.72
median	91.91	**88.49**	**86.38**
trimmed	91.94	89.05	87.30
clip	91.95	89.83	88.63
BALANCE	92.35	89.31	87.93
recip (B6)	91.85	89.80	88.02

Clean, 10 vòng cuối. Median/trimmed mất 0.8–1.4 pp audit do non-IID.

Sụt $\bar{q}$ láng giềng	λ=4	λ=8	λ=16
uniform	3.4/3.2/1.2	**20.6/26.2/15.5**	**55.9/61.4/49.4**
gate	0.8/1.5/0.5	0.0/0.5/−0.4	0.0/0.4/−0.4
median	0.9/1.1/−0.1	1.4/1.4/0.1	1.6/1.6/0.2
trimmed	1.3/1.1/−0.2	1.9/1.4/0.0	2.0/1.6/0.0
clip	0.8/1.3/−0.1	0.9/3.4/−0.1	1.0/9.9/−0.2
BALANCE	0.6/1.1/0.3	2.2/3.3/1.3	0.0/0.7/−0.2
recip	0.7/1.1/0.7	0.5/0.9/0.3	0.2/0.6/−0.2

pp, attacker 5 / 1 / 0, trung bình các vòng bị tấn công

Mọi defense đều **chặn được tấn công mạnh** ($\lambda \geq 8$). Vùng còn lại là $\lambda \approx 3$–5: dưới ngưỡng lọc, vẫn gây 0.5–1.5 pp.

B5 — Defense có làm tấn công bất lợi không?

Chi phí tới hạn c* (metric q, game lặp ρ = 1.25)

Defense	att 5	att 1	att 0
uniform	1.6e-3	1.3e-3	–
gate	–	–	–
median	–	–	–
trimmed	–	–	–
clip	–	4.7e-4	–
BALANCE	3.5e-4	4.7e-4	–
recip	–	8.4e-4	–

"–": không λ nào có lợi có ý nghĩa thống kê.

Nash N người (ρ = 1.25, c = 1e-4, metric q)

Defense	# attacker	q all-D → Nash	holdout
gate	0	91.90	—
median	0	91.91	—
trimmed	0	91.94	—
clip	2	91.95 → 79.96	0/2
BALANCE	10	92.35 → 85.91	0/10

- Clip/BALANCE: lọc theo **khoảng cách** để lọt tấn công trung bình → có profile nhiều attacker.
- Gate/median/trimmed: all-D là Nash theo q.

Nhưng metric q (val cục bộ non-IID) chưa phải toàn bộ câu chuyện → B6 kiểm tra lại theo audit.

B6 — Defense đề xuất “recip”: gate + có đi có lại

Luật (mỗi node, chỉ dùng thông tin cục bộ)

- Nhận: $\text{excess}_{ij} = L_i(m_j) - L_i(\ell_i)$; giữ m_j nếu excess ≤ `gate_tol` (1.0)
- Trust EMA: $T_{ij} \leftarrow \beta T_{ij} + (1-\beta)\mathbb{1}[\text{excess} \le \text{flag_tol}]$ (β = 0.5, flag 0.5 ≈ p99 excess trung thực)
- Gửi: $j \to i$ chỉ khi $T_{ji} \ge 0.75$; không nhận được ⟶ trust trôi về 1
- Cắt một chiều: attacker vẫn gửi ⟹ vẫn tạo bằng chứng ⟹ bị cắt liên tục; hai node trung thực cắt nhầm sẽ hồi phục

Chẩn đoán liên kết (`analyze_b6.py`)

λ (att 1)	**Gửi tới attacker**	**Msg attacker qua gate**
≤ 2	100%	100%
3	52.0%	92.0%
4	33.1%	72.9%
8	9.6%	49.6%
16	3.6%	12.9%

Clean: 97.57% liên kết trung thực được giữ (175/7200 bị cắt nhầm).

Cơ chế răn đe: láng giềng **ngừng gửi model cho attacker** ⟹ attacker mất lợi ích hợp tác (B1: +12.8 pp audit) ⟹ “own drop” tăng.

B6 — Nash theo metric audit: gate và recip thất bại

Defense	Metric	Profile Nash (ρ = 1.25, c = 1e-4)	audit all-D → Nash	holdout còn ý nghĩa
recip	q	node 1: λ = 3	89.80 → 89.19	**0/1**
recip	audit	16/16 tấn công, λ ∈ {2,3,4,8}	**89.80 → 81.12**	**11/16**
gate	audit	16/16 tấn công, λ ∈ {5,6,8,12}	**89.88 → 79.24**	**14/16**
uniform	audit	13/16 tấn công, λ ∈ {3,…,12}	**89.87 → 10.01**	2/13

- Theo audit, **mọi node đều tấn công** và lợi ích được xác nhận trên holdout (gate: +0.05 … +0.14 mỗi node).
- Nguyên nhân: gate dùng **val cục bộ non-IID** với tol 1.0 nats → message λ 3–8 vẫn qua gate (49–92%), gây hại theo audit cân bằng nhưng gần như vô hình theo q cục bộ.
- Uniform/audit: mạng sụp về 10% — trong trạng thái sụp, từng lệch đơn phương chỉ còn là nhiễu (2/13).

⇒ **Lệch thước đo**: bộ lọc nhìn phân phối khác với thứ utility đánh giá. Sửa ở B7: val **cân bằng** + ngưỡng hiệu chuẩn + trừng phạt tường minh.

B7 — Hiệu chuẩn ngưỡng với val cân bằng

Excess của message trung thực (n = 7200, t ≥ 10)

Phân vị	excess (nats)
p50	0.0023
p90	0.1029
p99	0.2185
p99.9	0.3073
max	0.3533

Tỷ lệ bị gắn cờ (excess > tol)

tol	trung thực	λ=2	λ=3	λ=4	λ=5	λ=8
0.10	10.53%	8.7%	90.9%	100%	100%	100%
0.20	1.51%	0.2%	75.8%	98.9%	99.9%	100%
0.30	**0.12%**	0.0%	56.5%	96.8%	99.9%	100%
0.50	0.00%	0.0%	18.0%	88.0%	97.7%	100%
1.00	0.00%	0.0%	0.1%	37.3%	82.7%	99.4%

- Chọn **tol = 0.3** (≈ p99.9 trung thực): báo động nhầm 0.12%, bắt 97% message λ = 4.
- λ = 2 **không phát hiện được** ở mọi ngưỡng hợp lý → vùng tấn công tồn dư; may mắn là nó gần như vô hại (B2: ≤ 0.5 pp).
- Biến thể W: `gate03` (gate tol 0.3), `recipEMA`, `recipL3` / `recipL10` (cắt L vòng sau mỗi cờ), **W2 = `recipL3G2`** (cắt 3 vòng + bắt buộc gửi 2 vòng ân xá → tránh vòng xoáy cắt nhầm).

B7 — Sàng lọc các biến thể W (chi phí tấn công hằng c_A)

Biến thể	audit	audit min	own drop s=4
uniform	89.87	88.70	0.7/0.9/1.0
gate10	89.87	88.70	0.2/0.6/0.6
gate03	89.88	88.68	−0.1/0.1/0.1
recipEMA	89.59	**85.22**	**5.8/3.6/4.9**
recipL3	89.58	**85.17**	**7.1/4.8/5.1**
recipL10	89.55	**85.16**	**8.8/5.9/6.6**
W2 L3G2	89.87	**88.68**	**3.1/2.0/2.5**

Clean all-D, val cân bằng; own drop: pp, metric q, attacker 5/1/0

$c_A^* \times 100$ (audit)	ρ = 1.25	ρ = 2
uniform	**21.6 / 23.5 / 22.1**	**9.2 / 8.9 / 11.0**
gate10	0.8 / 1.7 / 1.4	– / 1.4 / 0.8
gate03	0.3 / 0.7 / 0.7	– / 0.6 / 0.7
recipEMA/L3/L10	**– / – / –**	**– / – / –**
W2 L3G2	**– / – / –**	**– / – / –**

attacker 5 / 1 / 0, search seeds; "–" = không lợi ích có ý nghĩa

- Trừng phạt (recip) làm attacker **tự mất 2–9 pp** — kênh răn đe mà gate thuần không có.
- recip không ân xá: cắt nhầm lan rộng → node yếu nhất mất ≈ 3.5 pp. **Ân xá G = 2** giữ nguyên chất lượng node yếu (88.68) mà vẫn răn đe.

Kiểm tra cuối: all-D có phải Nash? (search → holdout, 16 node × 8 λ)

W (val)	clean q / audit	$c_A^* \times 100$, q	node có lợi (q)	$c_A^* \times 100$, audit	node có lợi (audit)
uniform (local)	91.20 / 89.73	**22.89**	0/16	**37.63**	**16/16**
gate tol 1.0 (local)	91.18 / 89.72	1.79	0/16	5.55	**9/16**
recip EMA (local)	91.07 / 89.36	4.04	2/16	4.13	1/16
gate tol 0.3 (bal)	89.99 / 89.72	2.42	2/16	1.59	5/16
W2 = recip L3 G2 (bal)	90.00 / 89.72	**2.56**	**0/16**	**2.34**	**0/16**

ρ = 1.25; c_A^* = max trên node của cận trên holdout (mean + 2.776 SE); "node có lợi" = lợi ích holdout có ý nghĩa. q của biến thể bal đo trên val cân bằng nên không so trực tiếp với local.

W2 là biến thể duy nhất có 0/16 node lệch có lợi ở cả hai metric với mọi ρ ∈ [1.25, 3] (audit ρ = 1: 1/16)
($c_A^* \times 100 \le 2.72$ cho q, ≤ 2.44 cho audit).
Chi phí hằng cần để all-D là Nash giảm từ ≈ 23–38 pp (uniform) xuống ≈ 2.3–2.6 pp.

- Mọi node W2 chọn $s = 2$: tấn công còn sót là loại **dưới ngưỡng phát hiện**, gây hại nhỏ.
- Không mất chất lượng khi sạch: audit 89.72 vs 89.73.
- Gate tol 1.0 rẻ theo q nhưng 9/16 node vẫn có lợi theo audit → thước đo quyết định kết luận.

Tổng kết phát hiện

B1	DFL hợp tác có giá trị lớn (+12.8 pp audit, node yếu +23 pp) ⟶ có cái để tấn công và có cái để mất.
B2	Thiệt hại có ngưỡng (λ ≈ 3–4) rồi lồi; lan theo hop; attacker tự chịu phần lớn thiệt hại.
B3	Best response **nhảy bậc** 0 ⟶ 6–8 tại $c^* \approx 10^{-3}$; ρ lớn (tự hại nặng) răn đe tự nhiên.
B4	Uniform: Nash có 1–2 attacker khi c nhỏ, kéo q cả mạng giảm 4.9–8.6 pp.
B5	Mọi defense chặn λ lớn; chỉ gate/median/trimmed giữ all-D Nash theo q; clip/BALANCE thì không.
B6	Theo audit, gate/recip với val cục bộ ⟶ **tất cả node tấn công** (xác nhận holdout 11–14/16): lỗi lệch thước đo.
B7	Val cân bằng + tol 0.3 + trừng phạt có ân xá: răn đe (own drop 2–3 pp) mà không mất chất lượng node yếu.
all-D	W2: 0/16 node có lợi ích lệch có ý nghĩa ở cả hai metric (ρ ≥ 1.25); c_A^* nhỏ hơn uniform 9–16×.

Thông điệp chính: lọc ≠ răn đe. Răn đe đến từ (1) bộ lọc nhìn **cùng thước đo** với utility và (2) **trừng phạt có đi có lại** làm attacker mất lợi ích hợp tác — có ân xá để không phá hợp tác trung thực.

Hạn chế và bước tiếp theo

Hạn chế hiện tại

- Một topology (lattice 4×4), một dataset (MNIST), một mức non-IID (α = 1)
- Lớp chính sách tấn công tĩnh (λ cố định từ vòng 10); chưa có attacker thích ứng/biết W
- W2 mới kiểm tra **lệch đơn phương** từ all-D; chưa chạy BR N người (B4) theo audit
- c_A^* của W2 vẫn > 0: cần giả định chi phí tấn công ≥ ≈ 2.6 pp
- Val cân bằng là giả định "dịch vụ kiểm định riêng" của mỗi node
- Chỉ 5 + 5 seed; tham số W2 (L = 3, G = 2, tol 0.3) chọn trên search seeds

Bước tiếp theo

1. B4-style BR N người cho W2 theo cả q và audit, kiểm tra holdout
2. Attacker thích ứng: λ thay đổi theo thời gian, nhắm vòng cuối (endgame), tấn công λ ≈ 2 kéo dài
3. Độ nhạy: topology small-world / scale-free, α ∈ {0.1, 0.5, ∞}, tỷ lệ attacker, IID
4. Loại tấn công khác: label flipping, backdoor
5. Chứng minh điều kiện: all-D Nash khi $c_A \geq \max_i G_i$ với cận cho G dưới W2
6. Khóa protocol rồi mới đánh giá trên official test